| 队伍编号 | MCB2606971 |
| --- | --- |
| 赛道 | A |

# 啤酒风味评分、关键化合物识别与风格生成

## 摘　要


啤酒风味由化学组成决定，但化合物谱到感官评分的映射多变量、非线性，附件数据又存在高维、缺失与标签不可观测三重困难。本文以 250 个样品的 231 个化合物特征、50 个感官维度与 22 个风格标签为基础，按**“基线—改进—最终”**逐层建模。

**针对问题一**，评分卡为空白，本文把任务拆为连续潜变量回归与有序校准两层：逐维均值与岭回归基线的宏平均 $R^2$ 为 $-0.029$ 与**0.162**，加入缺失指示与风格先验后升至**0.186**；最终用五类基学习器折外等权融合并做保序校准，5 折 $\times$ 3 次重复下取得 $R^2 = 0.227$、**Spearman 0.432**、**QWK 0.376**。酸度与酒精度（0.690/0.678）最易预测，阈值型缺陷维度接近 0；随机遮蔽 30% 时 $R^2$ 仅相对下降**19.3%**。

**针对问题二**，本文由化合物相关矩阵构建共表达图，每个节点保留 10 个强相关邻居，得到 231 个节点、1 683 条边、8 个社区，模块度**0.586**；社区与化学家族基本对齐——酒花萜类（C2、C8）、酵母酯类与醇类（C4、C6）、麦芽醛与呋喃（C5）各自成模块。排序层以边际相关为基线，补充弹性网、极端随机树、LightGBM 的 SHAP 值与网络拉普拉斯平滑，再做**Borda 秩融合** 得到每个感官维度的 Top-3。500 次 bootstrap 下平均入选频率**0.525**、方法间 Jaccard 系数**0.313**，说明单条目比整组更稳定。双乙酰、DMS 与反式-2-壬烯醛的纯数据 Top-3 均未选中同名化合物（融合名次**120.8**、**86.5**、**91.4**），本文另给机制导向名单，代价是与纯数据重合率降至**0.387**；而苦味（异 $\alpha$ 酸）、4VG（挥发性酚）与酒花柑橘香（萜醇）三条链条两栏一致。

**针对问题三**，本文把 70 个校准化合物变换到正态分数空间，用**条件高斯 copula** 学习各风格分布，以 Ledoit–Wolf 收缩协方差控制小样本风格；迁移用**高斯最优传输**的闭式映射，并以“严格阈值与风格 75% 分位数的较大者”作为缺陷上限。三风格平均的 **MMD 为 0.038**、**覆盖度 0.863**、**风格命中率 0.981**，优于均值加噪声（0.063/0.300/0.851）与全局协方差（0.066/0.233/0.667）；Pils/Lager 迁移为 Tripel 后命中率**由 0.00 升至 0.91**，严格投影下 DMS、双乙酰与反式-2-壬烯醛不恶化，相对风格上限的超标率为 0；Tripel、Kriek、Lambic 的生成画像与真实画像的 Pearson 相关为**0.968**、**0.957**、**0.990**。

关键词： 啤酒风味；缺失数据；多任务回归；共表达网络；稳定性选择；条件生成模型

# 目录


**1 问题重述** **1**

1.1 问题背景 . . . . . 1

1.2 数据说明 . . . . . 1

1.3 问题提出 . . . . . 2

1.4 技术路线 . . . . . 3

**2 数据预处理** **3**

2.1 符号说明 . . . . . 3

2.2 模型假设 . . . . . 4

2.3 数据概况与表间对齐 . . . . . 5

2.4 变量变换核验 . . . . . 5

2.5 缺失值与异常值处理 . . . . . 6

2.6 标准化与特征构造 . . . . . 7

2.7 外部数据 . . . . . 7

**3 问题一：数据缺失条件下的感官评分** **8**

3.1 问题分析 . . . . . 8

3.2 评价指标 . . . . . 8

3.3 模型构建：从基线到折外融合 . . . . . 9

3.3.1 基线模型：逐维均值与岭回归 . . . . . 9

3.3.2 改进模型：缺失指示与风格先验 . . . . . 10

3.3.3 最终模型：五模型折外等权融合 . . . . . 11

3.3.4 分级校准：由感官潜变量到 0–6 分 . . . . . 12

3.4 实验设置 . . . . . 12

3.5 结果与分析 . . . . . 13

3.6 讨论 . . . . . 14

**4 问题二：化合物——风味关联分析** **15**

4.1 问题分析 . . . . . 15

4.2 评价指标 . . . . . 15

4.3 模型构建：从共表达图到秩融合 . . . . . 16

4.3.1 共表达图的构建与社区结构 . . . . . 16
4.3.2 基线方法：边际相关排序 . . . . . 18
4.3.3 改进方法：共表达图上的拉普拉斯平滑 . . . . . 18
4.3.4 最终方法：五方法秩融合与稳定性选择 . . . . . 18
4.4 实验设置 . . . . . 19
4.5 结果与分析 . . . . . 19
4.6 稳定性与化学合理性论证 . . . . . 20
4.6.1 纯数据结果与机制导向结果的分工 . . . . . 20
4.6.2 化学合理性核对 . . . . . 22
4.7 讨论 . . . . . 22

**5 问题三：“风味指纹”与风格条件生成 23**
5.1 问题分析 . . . . . 23
5.2 风味指纹与评价指标 . . . . . 24
5.3 模型构建：从风格均值到缺陷约束 . . . . . 24
5.3.1 基线方法：风格均值与全局协方差采样 . . . . . 24
5.3.2 改进方法：条件高斯 copula . . . . . 25
5.3.3 最终方法：风格感知的缺陷约束 . . . . . 25
5.4 跨风格迁移：最优传输与边际校准 . . . . . 26
5.5 实验设置 . . . . . 27
5.6 结果与分析 . . . . . 27
5.7 讨论 . . . . . 29

**6 结论与建议 29**
6.1 主要结论 . . . . . 29
6.1.1 问题一 . . . . . 30
6.1.2 问题二 . . . . . 30
6.1.3 问题三 . . . . . 31
6.2 对酿造实践的建议 . . . . . 31
6.3 局限与展望 . . . . . 32

# 1 问题重述

## 1.1 问题背景

啤酒的风味、香气与口感由其化学组成决定[1]。酵母在糖代谢中生成乙醇与二氧化碳，并通过酯化反应和氨基酸的 Ehrlich 降解生成酯类与高级醇；酒花添加带来萜烯、萜醇与异$\alpha$酸[2]；麦芽提供美拉德产物与醛类；非酿酒酵母与细菌则可能产生双乙酰、4-乙烯基愈创木酚、二甲基硫（DMS）等缺陷物质[3]。同一种化合物在不同浓度区间对感官的贡献方向可能相反，多种化合物之间又存在共同代谢与共表达关系，因此“化合物谱—感官画像”是一个多变量、非线性的映射问题，仅靠单变量相关分析难以刻画其整体结构。

附件给出了 250 个商用啤酒样品的化合物丰度、化合物相关矩阵、感官评分卡与感官描述数据。这批数据源自 Schreurs 等对 250 款比利时商业啤酒的化学—感官联合测量[4]：每款酒测定 200 余项化学与理化指标，覆盖 22 个风格；感官侧由 16 人训练品评小组按 7 点量表对 50 个属性打分，并按品评员标准差缩放、中心化为 $z$ 分数。这一来源决定了两件事：`4.csv` 的感官列不是原始 0–6 分，不能反变换回量表；评分本身带有品评员间方差，故第 3 章把任务拆为连续潜变量回归与有序校准两层。这些数据同时覆盖化学测量、感官评价与文本描述三个层面，但并非为同一建模任务整理：化合物列的量纲与变换方式并不统一，感官表只提供标准化后的连续值，跨表主键还存在格式问题。上述特征决定了本文必须先统一数据口径，再针对三问分别建模。

## 1.2 数据说明

8 份附件数据的内容、规模与本文用途见表 1.1。

表 1.1　附件数据一览与本文用途

| 文件 | 主要内容 | 规模 | 本文用途 |
|---|---|---|---|
| 1.csv | 250 个啤酒样品的化合物丰度矩阵 | 250×234 | 问题一至三的主特征 |
| 2.csv | 化合物之间的相关系数矩阵 | 231×231 | 问题二共表达图边权 |
| 3.xlsx | Aroma 与 Flavour 两套评分卡 | 13 个 sheet | 问题一的维度定义 |
| 4.csv | 感官评分的标准化连续值 | 250×53 | 问题一、二监督信号 |
| 5.csv | 感官属性之间的相关矩阵 | 50×50 | 感官维度结构分析 |
| 6.csv | 化合物与感官属性的交叉相关矩阵 | 44×50 | 问题二一致性校验 |
| 7.csv | 感官描述符与风格标签 | 250×189 | 问题三的风格标签 |
| 8.xlsx | 感官阈值、校准化学数据与价格等 | 7 个 sheet | 阈值与变换核验 |

题面描述与附件实测存在一些出入，本文以附件实测为准：

（1） 题面称 226 种啤酒，1.csv 实为 250 个样品；

（2） 题面称 3.xlsx 含 10 个评分卡，实为 beer_1 至 beer_12 共 12 个 sheet 加 1 个 summary，且均为空白评分卡，不含已填写的分数；

（3） 题面称两套感官维度共约 40 个，实测每套 15 个、共 30 个，4.csv 另含 20 个 taste/palate/overall 维度，合计 50 个；

（4） 题面称 6.csv 为 46×50，实测 44 个指标与 50 个感官属性；

（5） 题面称 7.csv 为 250×187，实测 189 列。

其中后三条直接影响建模：可用的感官维度数、参与交叉相关的指标数、以及风格标签所在的列，都与题面口径不同。此外，4.csv 与 7.csv 的 beer_id 有 213/250 行存为科学计数法、仅 96 个唯一值，不能作连接键；本文一律用取值 1–250 且唯一的 beer 列连接，详见第 2 章。

## 1.3　问题提出

（1） **问题一：数据缺失条件下的感官评分。**以 1.csv 的化合物数据为基础，给出 3.xlsx 定义的 Aroma 与 Flavour 两套、共 30 个感官维度的 0–6 分分级评分。困难在于评分卡是空白的、没有可直接监督的等级标签，化合物维度 231 与样本数 250 同量级且存在 73 个缺失单元。

（2） **问题二：化合物—风味分析。**以 2.csv 构建化合物共表达图，结合 1.csv 的特征给出每个感官维度的 Top-3 关键因素化合物，并论证其稳定性与化学合理性。困

难在于化合物强共线，单个化合物的重要性会被相关化合物“分摊”，边际相关排序在重采样下不稳，且相关关系不等于因果关系。

（3） **问题三：风味与“风味指纹”生成。**以 `tasting_category_fine` 为风格标签学习条件生成模型，在给定风格（如 Tripel、Kriek、Lambic）下生成化合物谱与感官画像，并完成 Pils/Lager 到 Tripel 的跨风格迁移，同时保证 DMS、双乙酰、4VG、反式-2-壬烯醛与 stale hops 等缺陷化合物不恶化。困难在于 22 个风格样本量悬殊（最多 31 个、最少 3 个），逐风格建模易过拟合，且生成结果没有唯一真值。

### 1.4 技术路线

三问共享同一套数据底座与符号体系（第 2 章），先给出可复现的简单基线，再针对基线的具体缺陷逐层改进，最后用同一数据划分上的对比说明每一层改进是否必要。问题一解决“化合物到感官”的有监督映射；问题二给出该映射中少数关键化合物及其稳定性，为问题一的结果提供了可解释性检查；问题三反过来由风格标签生成化合物谱，并用问题一的模型为生成结果提供感官解释。三个问题可以相互校验，而不是三个彼此独立的模型。

整篇文章布局安排如下：第 2 章给出数据对齐、缺失处理、变换核验与符号约定；第 3 章至第 5 章分别回答问题一至问题三；第 6 章总结结论，并给出建议与局限。

## 2 数据预处理

### 2.1 符号说明

本文定义了如下使用次数较多的符号，其余符号在使用时注明。

表 2.1　主要符号及含义

| 符号 | 含义 | 维度/取值 |
|---|---|---|
| $N, P, S, G$ | 样本数、化合物数、感官维度数、风格类别数 | — |
| $i, j, s, g$ | 样本、化合物、感官维度、风格索引 | $i = 1, \ldots, N$ |
| $\boldsymbol{x}_i$，$\boldsymbol{X}$ | 第 $i$ 个样本的化合物特征向量、特征矩阵 | $\mathbb{R}^P$，$\mathbb{R}^{N\times P}$ |
| $y_{i,s}$，$\boldsymbol{Y}$ | 第 $i$ 个样本第 $s$ 维的评分、评分矩阵 | $\mathbb{R}$，$\mathbb{R}^{N\times S}$ |
| $z_i$ | 第 $i$ 个样本的风格标签 | $\{1, \ldots, G\}$ |
| $r_{j,j'}$，$\boldsymbol{R}$ | 化合物 $j$ 与 $j'$ 的相关系数、相关矩阵 | $[-1, 1]$，$\mathbb{R}^{P\times P}$ |
| $\boldsymbol{A}$ | 共表达图的邻接矩阵 | $\{0, 1\}^{P\times P}$ |
| $\boldsymbol{\beta}_s$，$\boldsymbol{B}$ | 第 $s$ 维的回归系数、系数矩阵 | $\mathbb{R}^P$，$\mathbb{R}^{P\times S}$ |
| $w_{j,s}$ | 化合物 $j$ 对感官维度 $s$ 的重要性 | $\mathbb{R}$ |
| $\hat{y}_{i,s}$ | 第 $i$ 个样本第 $s$ 维的模型预测 | $\mathbb{R}$ |

## 2.2　模型假设

本文结论建立在以下七条假设之上，各条的依据与检验位置一并注明。

**假设 1**　`1.csv` 各列在 250 个样本上的变换方式统一，即整列为 $\log_{10}$ 浓度或整列为线性浓度。依据是 `8.xlsx` 的校准数据对 70 个公共列给出唯一判定：37 列 $\log_{10}$、33 列线性，其余 161 列按负值与值域归类，式 (2.1) 的逐列还原据此建立。

**假设 2**　缺失位置与缺失值本身无关，或只依赖可观测变量。本题没有缺失原因的元数据，故该假设不可直接检验；3.4 节以 MCAR 5%–30% 与 MAR（按酒精度分层，平均 24.77%）两种遮蔽机制代替。

**假设 3**　`4.csv` 的标准化连续值与 `3.xlsx` 的 0–6 档位单调对应，同一维度内的样本排序与原始评分排序一致。评分卡为空白，只有单调性可依赖，故 3.2 节把分级结果定位为“校准后的相对等级”。

**假设 4**　50 个感官维度由少量共享的化合物因子驱动，但阈值型缺陷维度（`barnyard`、`clove`、`stale_hops`）不受该共享结构约束。目标间相关中位数仅 0.016，却存在 $r = 0.98$ 的强相关对，说明完全独立与整体低秩两端都不成立；3.6 节这类维度的 $R^2$ 接近 0 即为该假设失效的直接证据。

**假设 5**　`2.csv` 中的强相关对源于共同的原料、酵母菌株与工艺条件，而非两者之间

存在直接化学反应。表 4.1 的同一社区内混有酯、萜与醇即与此相符，故 Top-3 只表述为统计关联的标志物，不表述为致味因子。

**假设 6** 同一风格的化合物谱可由“风格原型 + 跨风格共享的低秩相关结构 + 逐维独立噪声”近似，风格差异主要体现在原型位置。22 个风格样本量为 3–31，逐风格协方差必然奇异，故式 (5.5) 向合并协方差收缩。

**假设 7** 缺陷化合物的浓度与其对应感官缺陷的强度单调不减，故“迁移后浓度不高于原值”可作为“缺陷不恶化”的可计算代理。该假设只保证变化方向、不保证幅度；`stale hops` 无对应化合物列，只能退化为感官层约束。

### 2.3 数据概况与表间对齐

附件各表的样本标识并不一致。`1.csv`、`4.csv` 与 `7.csv` 都含有 `beer` 列，取值为 1–250 的唯一编号；而 `beer_id` 在 `4.csv` 与 `7.csv` 中有 213/250 行被存成科学计数法，仅余 96 个唯一值，无法作为主键。本文因此以 `beer` 为唯一连接键建立样本主表，再逐表左连接，连接后核对各列的非空数量与取值范围。

主表为 250 行、231 个化合物特征。自然缺失共 73 个单元（占 0.12%），集中在 `amyl_acetate`（27）、`aroma_hops_sum`（13）、`methylpyrazine`（12）、`2,3-butanedione`（9）与 `3-methylbutanal`（7），并非均匀散布。`1.csv` 的 231 个特征列与 `2.csv` 的行列顺序逐位对应，这一对应关系既是两表可用的前提，也作为读取时的一致性断言。

感官目标共 50 维。各维标准化后的标准差在 0.37–0.86 之间，目标两两相关的中位数仅 0.016，但存在少量强相关对（最高 $r = 0.98$）。这说明 50 个维度既不能当作完全独立的任务，也不宜整体视为一个低秩问题，问题一对这两种设定都做了对照。

风格标签共 22 类，样本量高度不均衡：最多的 `Blond` 31 个、`Tripel` 28 个，最少的 `Faro` 仅 3 个。小样本风格在问题三中改用收缩估计，并单独报告其不确定性。

### 2.4 变量变换核验

`1.csv` 的化合物列并非统一变换。以 `8.xlsx` 的 Calibrated chemical dataset 为参照，对 70 个可校准列逐列比较校准浓度与 $10^{x_{i,j}}$、$x_{i,j}$ 的关系：37 列满足 calibrated $= 10^{x}$ 的 log10 关系， 33 列满足 calibrated $\approx x$ 的线性关系，两类的中位比值分别在 1 附近。其余 161 列没有对应的校准浓度，按含负值或值域小于 12 判定为 log10。据此

建立逐列变换表，还原关系为

$$x_{i,j}^{cal} = \begin{cases} 10^{x_{i,j}}, & j \in \mathcal{J}_{\log}, \\ x_{i,j}, & j \in \mathcal{J}_{\lin}, \end{cases} \tag{2.1}$$

其中 $\mathcal{J}_{\log}$ 为 37 个 log10 列与 161 个推断 log10 列的并集，$\mathcal{J}_{\lin}$ 为 33 个线性列。核对结果见表 2.2。

表 2.2　`1.csv` 逐列变换的核对结果

| 类型 | 列数 | 判定依据 | 典型列 |
|---|---|---|---|
| 校准 log10 | 37 | calibrated $= 10^x$ | `ethyl_acetate`、`DMS`、`pH` |
| 校准线性 | 33 | calibrated $\approx x$ | `linalool`、`geraniol`、`2,3-butanedione` |
| 推断 log10 | 161 | 含负值或值域小于 12 | `X4VG`、萜类、酯类 |

本次的建模不使用还原后的浓度，而是直接对逐列变换后的数值做分位数变换。原因有两个：一个是不同化合物的量纲相差数个数量级，直接给浓度会让正则化偏向大尺度的列；另一个是把 $10^x$ 误套到 33 个线性列上会引入系统性的数量级错误，而分位数变换是单调的，不依赖具体变换底数。浓度只在解释具体化合物时按式(2.1) 还原。

关于单位标注，`X.E..2.nonenal` 在附件中标注为 mg/L，但其数值范围（`Pils/Lager` 中位数 0.002、 `Tripel` 0.011）与文献常用的 $\mu$g/L 阈值处于同一量级，本文按 $\mu$g/L 解释；若按标注单位，全部样本都远低于检测限，该维度将失去区分度。这一判断在问题三的阈值约束中沿用。

### 2.5　缺失值与异常值处理

记缺失掩码为 $\boldsymbol{M} \in \{0,1\}^{N \times P}$，$m_{i,j} = 1$ 表示第 $i$ 个样本第 $j$ 个化合物被观测到；缺失机制对插补的影响按 Little 与 Rubin 的框架处理[5]。处理遵循两条原则。第一，插补、标准化与阈值选择只在训练折内拟合，验证折与测试折只做变换，避免信息泄漏；第二，插补方法作为敏感性分析的一个因素，而不是只保留一种“最优”结果。

基线插补取训练折内逐列中位数，问题一另加缺失指示特征，使模型能区分“浓度低”与“未检测”；问题三对校准浓度中仅有的 3 个负值（`betaglucan.mg.L.` 与 `unfermentables`）截断为 0。

异常值不做统一删除。化合物侧的极端值多对应真实的风味差异，例如特种麦芽带来的高色度、野生菌风格的高挥发酚，删除会连同风格信息一起丢掉。本文改在分位数变换、问题三的 log1p 与稳健区间映射中降低其影响，并在结果中保留极端样本，观察它们是否稳定落在同一风格。

### 2.6 标准化与特征构造

逐列变换后量纲差异仍然很大，本文在训练集内对各列做标准化

$$\tilde{x}_{i,j} = \frac{x_{i,j} - \mu_j}{\sigma_j}, \tag{2.2}$$

其中 $\mu_j$、$\sigma_j$ 为训练集第 $j$ 列的均值与标准差。对组成型数据，另做中心对数比变换作为敏感性分析，以检查结论是否依赖单一变换。

特征构造以可解释为先。主特征保留 231 个原始化合物列；按 `8.xlsx` 的 Sensory names 与化合物来源，把化合物归入酒花萜类、酵母酯类、高级醇类、醛酮类、麦芽来源与其他六组，构造组内均值与总和； DMS、双乙酰、4VG 与反式-2-壬烯醛四项缺陷化合物单独成组，供问题三的阈值约束与问题二的合理性解释使用。这里没有做 PCA 或自编码器降维：231 维相对于 250 个样本确实偏高，但降维后的成分不再对应任何具体化合物，与问题二、问题三需要指名化合物的要求相冲突，而正则化与低秩约束已经能承担控制方差的作用。

### 2.7 外部数据

题目给出的 Kaggle Top Beer Information 数据集[6]已经实际下载并核对：主表 5,558 行、21 列，内容为 BeerAdvocate 评论的词频统计，许可为 CC BY 4.0。

该数据不能与附件逐酒合并。附件 250 款酒在全部表格中都没有酒名、酒厂或条码，Kaggle 一侧也没有条码；退而用同风格且 ABV 相差 0.3 以内作代理匹配，每款附件酒的候选数中位数为 16、最多 407，且有 9 款无候选，匹配结果没有办法确认到具体酒款。

所以本文只在风格层级使用该数据：把 Kaggle 的 112 个风格按语义归并到附件的 22 个风格，96 个映射成功，覆盖 4,760/5,558 行（85.6%），据此构建 $22 \times 11$ 的风格感官原型。用途有三个：为问题一提供风格级先验，为问题三提供风格原型与迁移方向，和用于风格级的外部校验——风格级 ABV 与附件风格均值的相关为 0.855，而 IBU 仅为 0.449，所以不把 IBU 作为协变量。

上述相关都建立在 22 个风格上，属于生态相关，不能外推到个体样本。外部数据只作风格级辅助，不替代附件本身的化合物与感官建模。

# 3 问题一：数据缺失条件下的感官评分

## 3.1 问题分析

问题一要求由 `1.csv` 的化合物数据给出 Aroma 与 Flavour 两套共 30 个感官维度的 0–6 分评分；`4.csv` 另含 20 个 taste/palate/overall 维度，本文对 50 维一并建模，结果以 30 维为核心。这项任务有三处不同于常规回归，直接决定了模型的组织方式。

**第一，没有可直接学习的等级标签。**`3.xlsx` 的评分卡只有 0–6 档位与公式，没有填写的分数；`4.csv` 与 `7.csv` 给出的是各自标准化后的连续值，中心化基准不同，反变换得到的等级不可比。本文因此把任务拆成两层：先回归连续感官潜变量，再用单调映射锚定到 0–6。

**第二，化合物侧高维、共线且含缺失。**231 个特征对应 250 个样本，同源化合物高度相关，逐维回归的方差很大；73 个缺失单元的位置也不随机，若只做中位数插补，模型可能把“未检测”读成“浓度低”。模型因此需要显式缺失掩码，并在维度之间共享信息。

**第三，50 个感官维度彼此相关但并不共线。**目标两两相关的中位数仅 0.016，却存在 $r = 0.98$ 的强相关对；完全独立建模会丢掉共享结构，强行低秩又会欠拟合阈值型的缺陷维度。最终方案取“多输出共享、非线性补充、等权融合”，而不是在两者中二选一。

## 3.2 评价指标

设测试集有 $n$ 个样本、$S$ 个感官维度，$y_{i,s}$ 与 $\hat{y}_{i,s}$ 分别为观测值与预测值。连续拟合程度用宏平均决定系数、平均绝对误差与均方根误差衡量：

$$\bar{R}^2 = \frac{1}{S}\sum_{s=1}^{S}\left(1 - \frac{\sum_{i=1}^{n}(y_{i,s}-\hat{y}_{i,s})^2}{\sum_{i=1}^{n}(y_{i,s}-\bar{y}_s)^2}\right), \tag{3.1}$$

$$\mathrm{MAE} = \frac{1}{nS}\sum_{i=1}^{n}\sum_{s=1}^{S}\left|\hat{y}_{i,s}-y_{i,s}\right|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{nS}\sum_{i=1}^{n}\sum_{s=1}^{S}(\hat{y}_{i,s}-y_{i,s})^2}, \tag{3.2}$$

其中 $\bar{y}_s$ 为维度 $s$ 的样本均值。$R^2$ 先按维度计算再取平均，避免少数方差大的维度主导总分数；若直接把 50 维拼接后计算，方差大的维度会掩盖其余维度的拟合情况。

排序一致性用平均 Spearman 秩相关衡量，对第 $s$ 维

$$\rho_s = 1 - \frac{6\sum_{i=1}^{n} d_{i,s}^2}{n(n^2-1)}, \qquad \bar{\rho} = \frac{1}{S}\sum_{s=1}^{S}\rho_s, \tag{3.3}$$

其中 $d_{i,s}$ 为第 $i$ 个样本在观测值与预测值两个排序中的名次差。$\bar{\rho}$ 只关心顺序而不关心绝对水平，是判断“分级是否可用”的必要条件。

分级一致性用二次加权 Kappa 衡量[7]。设 $O_{k,k'}$ 为真实等级 $k$ 被判为 $k'$ 的频数，$E_{k,k'}$ 为独立假设下的期望频数，取二次权重 $W_{k,k'} = (k-k')^2/36$，则

$$\mathrm{QWK} = 1 - \frac{\sum_{k=0}^{6}\sum_{k'=0}^{6} W_{k,k'}O_{k,k'}}{\sum_{k=0}^{6}\sum_{k'=0}^{6} W_{k,k'}E_{k,k'}}. \tag{3.4}$$

二次权重使“差一档”与“差三档”的惩罚不同，适合有序等级；随机猜测的 QWK 约为 0，完全一致为 1。

这里必须交代一个口径问题。由于附件没有填写的 0–6 分数，本文的“参考分级”是把连续监督信号按训练折内 $q_{0.01}$ 与 $q_{0.99}$ 做稳健区间映射后取整得到的离散结果，它是同一信号的单调重标度，不含人工评分的绝对档位信息。因此式(3.4) 报告的 QWK 衡量的是“同一连续信号在两种离散化下的一致性”，性质上接近离散化后的秩相关，不等于与人工评分逐档吻合。本文把分级结果定位为“校准后的相对等级”，并在结果中如实报告其偏差方向。

## 3.3 模型构建：从基线到折外融合

### 3.3.1 基线模型：逐维均值与岭回归

第一个基线不使用化合物信息，只用训练集均值预测：

$$\hat{y}_{i,s}^{(0)} = \bar{y}_s, \qquad \bar{y}_s = \frac{1}{N}\sum_{i=1}^{N} y_{i,s}. \tag{3.5}$$

它的作用是给出“完全不含化合物信息”时的参照：实测 $\bar{R}^2 = -0.029$，略低于以测试集均值为参照的 0（$R^2 = 0$ 对应恰好预测均值），因此后续任何正的 $R^2$ 都说明模型确实从化合物中取到了信息，而不是靠平凡预测撑起来的。

第二个基线是逐维岭回归与 PLS2[8;9]。设 $\boldsymbol{\beta}_s \in \mathbb{R}^P$ 为第 $s$ 维的回归系数，$c_s$ 为截

距，$\boldsymbol{B}=[\boldsymbol{\beta}_1,\ldots,\boldsymbol{\beta}_S]$，则

$$\min_{\boldsymbol{B},\{c_s\}}\ \sum_{i=1}^{N}\sum_{s=1}^{S}\left(y_{i,s}-\boldsymbol{x}_i^{\top}\boldsymbol{\beta}_s-c_s\right)^2+\lambda\|\boldsymbol{B}\|_F^2. \tag{3.6}$$

式(3.6) 通过一个共享的正则化强度降低小样本下的方差；PLS2 则把 $\boldsymbol{B}$ 约束为低秩，用少量潜变量同时解释多个感官维度，是多任务共享最简单的形式。两者都不使用缺失指示与风格信息，作为后续改进的对照。

第三个基线不使用化合物信息，只用风格标签。设样本 $i$ 的风格为 $z_i$，该风格在训练折内的样本数为 $n_{z_i}$，预测取风格均值与全局均值的平滑混合：

$$\hat{y}_{i,s}^{\text{style}}=\frac{n_{z_i}\,\bar{y}_{z_i,s}+\kappa\,\bar{y}_s}{n_{z_i}+\kappa}, \tag{3.7}$$

其中 $\bar{y}_{z_i,s}$ 为风格 $z_i$ 在训练折内第 $s$ 维的均值，$\bar{y}_s$ 为全局均值。取 $\kappa=5$ 是因为样本量最少的 `Faro` 仅 3 个样本，不收缩会让其预测完全由这 3 款酒决定；训练折内未出现的风格回退到 $\bar{y}_s$。该基线比逐维均值严格：它承认“知道风格即已知大部分感官期望”，化学特征的增益必须在它之上仍然成立，才能说明化合物谱提供了风格之外的信息。

式 (3.7) 的结果见表 3.1。三个基线与最终模型在同一划分、同一评估口径下计算；改进量的区间按啤酒配对 bootstrap（$B=2000$）给出，而非按“啤酒 × 维度”的单元独立抽取——同一款酒的 50 维误差高度相关，按单元抽取会把区间压窄。

表 3.1　问题一相对两类无化学基线的改进（5 折× 3 次重复，50 维宏平均）

| 对照 | 宏平均 $\bar{R}^2$ | 相对最终模型的差值 | 配对 bootstrap 95% 区间 |
|---|---|---|---|
| 逐维均值 | −0.029 | 待填 | 待填 |
| 风格均值（$\kappa=5$，式 (3.7)） | 待填 | 待填 | 待填 |
| 最终：五模型折外等权融合 | 0.2270 | — | — |

风格均值基线的 $\bar{R}^2$ 为待填，最终模型高出待填，但配对区间待填跨零。因此“化学特征改善预测”这一结论只在相对无条件均值时成立，不能表述为稳定超过仅用风格标签的估计；这一限制与式 (3.8) 的风格先验消融结果（融合模型上仅 +0.012）指向同一事实。

### 3.3.2　改进模型：缺失指示与风格先验

改进模型加入两条数据事实。

其一是缺失。在训练折内做中位数插补的同时，把“该列是否缺失”作为 0/1 指示特征拼入特征向量，使模型能区分“浓度低”与“未检测”。其二是风格。`1.csv` 自带风格标签 $z_i$，而同一化合物谱在不同风格下的感官期望并不相同，因此把风格信息作为附加特征：

$$\tilde{\boldsymbol{x}}_i = [\boldsymbol{x}_i;\ \boldsymbol{M}_i;\ \boldsymbol{s}_{z_i}], \tag{3.8}$$

其中 $\boldsymbol{M}_i$ 为第 $i$ 个样本的缺失指示向量，$\boldsymbol{s}_{z_i}$ 为风格的 one-hot 编码或该风格在训练折内的感官均值（目标编码）。目标编码用留一与平滑（平滑系数 10）估计，避免把当前样本的标签泄漏进特征。

需要说明，风格先验不是用标签作弊：风格是 `1.csv` 的既有列，且在真实品评流程中，品评员在打分前已知酒的风格。为量化它的作用，本文同时报告仅用化合物与加入风格先验两组结果（表 3.3）。

### 3.3.3 最终模型：五模型折外等权融合

单一模型对共线的化合物与其中的非线性关系都不够稳健。最终模型用五类互补的学习器得到折外预测：PLS2（低秩多任务）、岭回归（线性）、极端随机树与随机森林（非线性、原生多输出）、LightGBM（逐维提升）。记第 $\nu$ 个学习器对样本 $i$、维度 $s$ 的折外预测为 $\hat{y}_{i,s}^{(\nu)}$，学习器集合为 $\mathcal{M}$，比较两种融合：

$$\hat{y}_{i,s}^{\text{avg}} = \frac{1}{|\mathcal{M}|}\sum_{\nu\in\mathcal{M}} \hat{y}_{i,s}^{(\nu)}, \qquad \hat{y}_{i,s}^{\text{stack}} = \sum_{\nu\in\mathcal{M}} \omega_{\nu,s}\hat{y}_{i,s}^{(\nu)} + b_s, \tag{3.9}$$

其中 $\omega_{\nu,s}$ 在折外预测上用岭回归拟合。等权融合不估计额外权重，因而没有第二层过拟合风险；堆叠可以按维度分配权重，但元学习器是在训练折的折外预测上拟合的，这些预测又来自包含当前测试折样本的模型，存在乐观偏置。实测等权融合的 $\bar{R}^2$ 为 0.227，高于堆叠的 0.216，且折间方差更小；即便带着上述偏置，堆叠仍未超过等权，本文因此以等权融合为最终方案，堆叠作为对照保留。

融合之所以有效，是因为五类模型在不同维度上各有胜负：线性模型在酸度、苦味这类与化合物近乎单调相关的维度上更好，树模型在酒花与麦芽的复合香型上更好，等权平均让两者的误差互相抵消，而不需要额外的权重估计。

这一增益的幅度必须说清。五个单体的宏平均 $\bar{R}^2$ 依次为：极端随机树 0.223、随机森林 0.217、岭回归 0.162、PLS2 0.141、LightGBM 0.137，逐维均值基线为 $-0.029$。等权融合的 0.227 相对最强单体（极端随机树）只高 0.004，两者折间误差棒重叠，因此融合的收益不能表述为“显著更高”，它的实际价值在于折间标准差更小与逐目标

表现更均衡。堆叠的情况同样需要交代：Ridge 堆叠在 RMSE（0.469）与 Spearman（0.433）上均以 0.001 量级微弱优于等权融合，仅 $\bar{R}^2$（0.216）落后。本文以 $\bar{R}^2$ 为主、并计入堆叠的乐观偏置与更大的折间方差，选择等权融合；这属于近似打平下的取舍，而非全面占优。

#### 3.3.4 分级校准：由感官潜变量到 0–6 分

连续预测存在向均值收缩的问题，直接做 min-max 会把所有样本挤到中间几档。本文先在训练折内拟合单调映射：用保序回归 $g_s$ 把预测值映射到观测的连续值，再做稳健区间映射，

$$\hat{k}_{i,s} = \mathrm{round}\left(6 \cdot \frac{g_s(\hat{y}_{i,s}) - q_{0.01,s}}{q_{0.99,s} - q_{0.01,s}}\right), \qquad \hat{k}_{i,s} \in \{0, \ldots, 6\}, \tag{3.10}$$

其中 $q_{0.01,s}$、$q_{0.99,s}$ 为训练折内 $g_s(\hat{y}_{\cdot,s})$ 的 1% 与 99% 分位数，越界值截断到端点。保序回归只要求单调、不假设线性，能够纠正收缩而不改变样本间的顺序；稳健区间映射只负责把校准后的值锚定到 0–6 档。

分级结果对校准方案并不免疫。本文另对 raw min-max、quantile rank、quantile map、linear recalibration 与 Gaussian latent 五种替代校准做了同样的评估，六种方案的宏平均 QWK 分布在 0.276（quantile rank）到 0.441（quantile map）之间，跨度 0.165，说明分级结论确实依赖这一层假设。本文仍以保序回归为主方案，理由是它同时给出最低的等级平均绝对误差（0.83 档；quantile map 为 0.95 档）：分级结果会作为问题三感官画像的输入，逐档偏差对下游的影响大于整体秩一致性。若下游只关心排序而不关心档位，quantile map 的 QWK 更高，是更合适的选择，这一点在讨论中作为备选方案保留。

### 3.4 实验设置

数据划分与评估。按样本做 5 折、重复 3 次（随机种子 42），共 15 折；插补、标准化、分位数变换、保序校准与超参数选择全部在训练折内完成，验证折与测试折只做变换。

超参数在外层训练折内用内层交叉验证选择，不跨折固定：岭回归的 $\alpha$ 在 $[10^0, 10^6]$ 上取 13 点对数网格，内层 5 折；PLS 成分数在 2–20 之间，内层 5 折；极端随机树与随机森林的叶节点数在 $\{1, 2, 4\}$ 中选，调参时用 200 棵、最终 500 棵；LightGBM 固定 400 棵、学习率 0.03、叶节点 15、行与列采样各 0.8、$L_2$ 正则 1.0；堆叠元学习器为 RidgeCV，$\alpha \in [10^{-3}, 10^2]$、内层 3 折。

缺失模拟。除自然缺失外，在测试集上按比例随机遮蔽化合物构造 MCAR 情形（5%、10%、20%、30%），并构造一种非随机缺失（MAR）情形：按 `ethanol..v.v.` 的四分位分层决定遮蔽概率，使高酒精度样本更容易被遮蔽，平均缺失率 24.77%。前者检验插补与缺失指示在随机机制下的效果，后者检验缺失与观测值相关时是否产生系统偏差。

对照设置。共五组：（1）逐维均值；（2）逐维岭回归；（3）多输出岭回归与 PLS2；（4）式(3.9) 的等权融合；（5）去掉风格先验、去掉保序校准或去掉树模型的消融版本。所有对照在同一划分上比较，避免“换了数据又换了模型”。

### 3.5 结果与分析

三种路线的重复交叉验证结果见表 3.2。最终模型的宏平均 $R^2$ 为 0.227，相对逐维岭回归的 0.162 提升 0.065；平均 Spearman 从 0.373 升到 0.432；MAE 与 RMSE 分别下降 5.7% 与 5.1%。

表 3.2 问题一三种路线的重复交叉验证结果（5 折× 3 次重复，50 维宏平均）

| 模型 | $\bar{R}^2$ | MAE | RMSE | 平均 Spearman | QWK |
|---|---|---|---|---|---|
| 基线：逐维岭回归 | 0.1617 | 0.3622 | 0.4946 | 0.3728 | — |
| 改进：岭回归 + 缺失指示 + 风格先验 | 0.1855 | 0.3542 | 0.4855 | 0.3927 | — |
| 最终：五模型折外等权融合 + 保序校准 | **0.2270** | **0.3415** | **0.4695** | **0.4318** | 0.3756 |

表中前四列为 15 折的折间均值，QWK 只对最终方案报告——基线与改进尚未做分级校准，报告 QWK 没有可比性。最终模型的折间标准差为 $R^2$ 0.021、Spearman 0.024、RMSE 0.018、MAE 0.011，说明结果不依赖某一次划分。

改进的幅度不大，但方向一致。把 50 个维度拆开看，$R^2 > 0.3$ 的有 14 个，最强的是 acidity（0.690）、alcohol（0.678）、lactic（0.648）、acetic（0.635）与 bitternes（0.604）；最弱的是 barnyard（−0.039）、stale_hops（−0.032）与 clove（−0.005）。这一分布与化学直觉一致：酸度、酒精度、苦味有明确的化学载体（有机酸、乙醇、异 $\alpha$ 酸），其浓度与感官强度近似单调；而 barnyard 由 4-乙基苯酚与 4-乙基愈创木酚等痕量酚类决定，clove 由 4VG 决定，二者都只在超过阈值后才被感知，且在同一风格内部变异很小，231 个化合物特征提供不了足够的区分信息。缺陷维度的可预测性弱，这一点在问题二中会以另一种形式再次出现。

风格先验的消融结果见表 3.3。它在岭回归上带来 +0.024 的提升，在融合模型上

只带来 +0.012。原因是融合模型中的树模型已能从化合物谱间接识别风格，风格先验的边际信息被吸收掉了。综合考虑后，最终交付以仅用化合物的融合模型为主，加入风格先验的版本作为消融报告，以免把“用标签换精度”当成主要贡献。

表 3.3　风格先验的消融（$\bar{R}^2$）

| 模型 | 仅用化合物 | 加入风格先验 | 变化 |
|---|---|---|---|
| 逐维岭回归 | 0.1617 | 0.1855 | +0.0238 |
| 五模型折外等权融合 | 0.2270 | 0.2388 | +0.0118 |

缺失条件下的退化见表 3.4。以自然缺失（0.13%）下的 $R^2 = 0.2264$ 为基准，随机遮蔽 5%、10%、20%、30% 时 $R^2$ 分别相对下降 3.5%、6.3%、11.5%、19.3%，RMSE 相对上升 0.7%、1.2%、2.3%、3.8%；退化随缺失率近似单调，没有出现断崖。非随机缺失（平均 24.77%）下的下降为 10.9%，与同量级的随机缺失（20% 时 11.5%）接近，说明在本文的遮蔽机制下没有明显的额外偏差。

表 3.4　缺失模拟下的性能变化（基准为自然缺失，$\bar{R}^2 = 0.2264$）

| 情形 | 平均缺失比例 | $R^2$ 相对变化 | RMSE 相对变化 |
|---|---|---|---|
| 自然缺失 | 0.13% | 0 | 0 |
| MCAR 5% | 5.00% | −3.46% | +0.70% |
| MCAR 10% | 10.00% | −6.33% | +1.15% |
| MCAR 20% | 20.00% | −11.46% | +2.28% |
| MCAR 30% | 30.00% | −19.33% | +3.75% |
| MAR（按酒精度分层） | 24.77% | −10.89% | — |

分级校准的效果体现在等级分布上。直接对融合预测做 min-max 时，被预测为 0 级的样本仅占 7.6%；加保序回归后升至 11.3%，参考分级中 0 级占 23.3%。校准明显缓解了“向中间档压缩”，但仍低估尾部，QWK 为 0.376，属于中等一致。这与前面的口径说明相符：模型能保持样本间的相对顺序与等级单调性，但不足以复现人工评分的绝对档位分布。

## 3.6　讨论

问题一的主要困难不在模型复杂度，而在标签不可直接观测。本文用“连续监督加有序校准”绕开了空白评分卡的限制，代价是最终 0–6 分数的绝对水平依赖校准锚

点。稳妥的表述是：在给定校准方案下，模型保持了样本间的相对顺序与等级单调性；若要报告绝对等级精度，需要原始评分或专家复核数据。

其次是低秩假设的边界。多输出共享假定不同感官维度由少量共同因子驱动，这与目标间相关结构的中位数偏低、存在少量强相关对的事实相符，但对阈值型维度并不成立，表现为这类维度的 $R^2$ 接近 0 甚至为负。可行的改进是允许部分维度使用独立残差项，或在低秩模型与逐维模型之间做模型平均，本文未进一步展开。

最后是缺失机制。掩码指示与折内插补在随机缺失下近似无偏，在非随机缺失下只能减轻偏差而不能消除。若后续能拿到缺失原因的元数据（例如某化合物未检测而非浓度为零），应把缺失原因作为额外变量纳入模型，而不是用一个 0/1 掩码近似。

# 4 问题二：化合物——风味关联分析

## 4.1 问题分析

问题二要求为每个感官维度给出 Top-3 关键因素化合物，并论证其稳定性与化学合理性。它要的不是预测精度最高的模型，而是在 231 个高度共线的化合物中找出对某个维度既有统计支持、又有化学解释的少数变量。

可用的信息有三类：`2.csv` 刻画“哪些化合物共同变化”，`1.csv` 刻画“样本间差异有多大”，`6.csv` 刻画“已有数据中是否观察到对应关系”。可用的 Top-3 应在这三类信息上都不出现明显矛盾，而不是只在一张相关矩阵上排到前列。

主要困难是共线导致的排序不稳。同一代谢路径或同一酒花组分产生的化合物彼此高度相关，单个化合物的边际相关会被相关化合物“分摊”，重采样时名次相邻的几个化合物互相挤占 Top-3，“取绝对值最大的三个”得到的是一份随样本波动的名单。其次是相关与因果的区分：共表达图上的边可能来自共同上游调控、批次差异或样品制备，不能直接当作化学作用。

本文因此分三步处理：先构建共表达图刻画模块结构，再在图上排序得到候选，最后用多方法秩融合、bootstrap 重采样[10]与化学类别核对确定 Top-3，并把稳定性作为独立信息报告，而不是用它二次筛选。

## 4.2 评价指标

与问题一不同，本题没有预测精度意义上的“真值”，评价必须落在结构、排序与外推一致性三个层面。

图层面用模块度 $Q$、社区数、孤立点数与方案间的调整兰德指数（ARI）衡量。$Q$

越大说明模块结构越清晰，但 $Q$ 会随边数增加而虚高，因此必须与孤立点数一起看：把所有节点连成一张近乎完整的图也能得到很高的 $Q$，却失去了筛选意义。

排序层面用 bootstrap 入选频率与方法间 Jaccard 系数。对第 $s$ 个感官维度重复 $B$ 次有放回重采样，第 $b$ 次得到的 Top-3 集合记为 $\mathcal{T}_s^{(b)}$，则化合物 $j$ 的入选频率为

$$\pi_{j,s} = \frac{1}{B}\sum_{b=1}^{B} \mathbf{1}\left\{j \in \mathcal{T}_s^{(b)}\right\}. \tag{4.1}$$

两种方法 $\nu$ 与 $\nu'$ 给出的 Top-3 集合之间的一致性为

$$J\left(\mathcal{T}_s^{(\nu)}, \mathcal{T}_s^{(\nu')}\right) = \frac{\left|\mathcal{T}_s^{(\nu)} \cap \mathcal{T}_s^{(\nu')}\right|}{\left|\mathcal{T}_s^{(\nu)} \cup \mathcal{T}_s^{(\nu')}\right|}. \tag{4.2}$$

$\pi_{j,s}$ 衡量单条目在重采样下的稳定性，$J$ 衡量不同建模方法之间的一致性，二者缺一不可：一组 Top-3 可能单独看都很稳（$\pi$ 高），但方法之间完全不重合（$J$ 低），说明结论依赖具体的建模假设。

外推一致性用 `6.csv` 校验。`6.csv` 给出 44 个化合物与指标同 50 个感官属性的两两相关，本文用它与排序结果比对符号与名次，并注意它本身也是边际相关，不控制共线，因此只能验证方向与量级，不能当作独立复现。

这里需要说明一处数据口径。题面称 `2.csv` 为皮尔逊相关，而附件的数据说明写的是 Spearman，两者不一致；本文只使用 $|r|$ 的相对大小构建图，不解释系数的绝对强度，故这一不一致不影响结论。`6.csv` 按 Spearman 使用，与方法 A 的口径一致，这也是后文“方法 A 与 `6.csv` 的秩相关接近 1”的原因。

### 4.3 模型构建：从共表达图到秩融合

#### 4.3.1 共表达图的构建与社区结构

设化合物 $j$ 与 $j'$ 的相关系数为 $r_{j,j'}$（取自 `2.csv`），邻接矩阵 $\boldsymbol{A}$ 的元素定义为

$$a_{j,j'} = \begin{cases} 1, & |r_{j,j'}| \geq \eta \text{ 或 } j' \in \mathcal{N}_K(j), \\ 0, & \text{否则}, \end{cases} \qquad a_{j,j} = 0, \tag{4.3}$$

其中 $\mathcal{N}_K(j)$ 为与 $j$ 相关性最强的 $K$ 个邻居。阈值 $\eta$ 在实际数据上很难同时满足“不产生大量孤立点”与“模块清晰”两个要求：取 $|r| \geq 0.5$ 时图只剩 645 条边、却有 48 个孤立点（占 21%），这些孤立点正是后续无法排序的化合物。本文因此改用 $K$ 近邻

图，它保证每个节点都有边，$K$ 由验证集上的模块度与下游稳定性共同选定。

图的拉普拉斯矩阵与度为

$$\boldsymbol{L} = \boldsymbol{D} - \boldsymbol{A}, \qquad d_j = \sum_{j'=1}^{P} a_{j,j'}, \tag{4.4}$$

其中 $\boldsymbol{D} = \mathrm{diag}(d_1, \ldots, d_P)$。对 $\boldsymbol{L}$ 做特征分解可得到低频模块结构[11]，本文用模块度与社区划分检查图是否把已知的化学类别分开。

$K = 10$ 时得到 231 个节点、1,683 条边（密度 0.063）、8 个社区，模块度 $Q = 0.586$。与两个对照相比：$K = 5$ 时 865 条边、$Q = 0.703$，模块度更高但边数少一半，Top-10 与 Top-5 两种方案的社区划分 ARI 只有 0.558，说明结论对 $K$ 并不稳健，这本身就是一个需要报告的稳定性事实；$|r| \geq 0.5$ 时 645 条边、$Q = 0.663$，但代价是 48 个孤立点。综合考虑，本文取 $K = 10$ 为主方案：它在保留全部节点的前提下维持了可辨识的模块结构。

8 个社区与化学类别的对应关系见表 4.1。需要说明的是，社区并不严格等于化学家族：同一社区内往往混有酯、萜与醇，这是因为它们受同一发酵条件（温度、酵母菌株、酒花添加量）共同驱动。因此社区只作为“哪些化合物应一起考虑”的先验，最终的化学合理性仍需逐化合物核对。

表 4.1　共表达网络的 8 个社区及其化学构成

| 社区 | 节点数 | 主要来源与类别 | 代表成员 |
|---|---|---|---|
| C1 | 40 | 酵母与酒花：酯、萜、醇、醛 | E-nerolidol、2,3-dihydrofarnesol |
| C2 | 34 | 酒花：萜类与酯 | nerol oxide、epicubenol |
| C3 | 32 | 酒花、酵母与野生菌：酯、挥发性酚 | ethyl phenylacetate、neryl formate |
| C4 | 29 | 酵母：酯、醇、硫、理化指标 | ethanol、isopentyl acetate |
| C5 | 28 | 麦芽与酵母：醛、呋喃、吡嗪、双乙酰 | diacetyl、2-pentylfuran |
| C6 | 24 | 酵母与酒花：以酯为主（16/24） | 2-methylbutyl octanoate |
| C7 | 22 | 酵母与酒花：醇、酯、萜 | 3-methyl-2-hexanol、o-cresol |
| C8 | 22 | 酒花与香料：以萜类为主（11/22） | isoborneol、terpinen-4-ol |

#### 4.3.2 基线方法：边际相关排序

最直接的 Top-3 是逐化合物计算与目标感官维度的边际相关，取绝对值最大的三个：

$$w_{j,s}^{(0)} = \left|\mathrm{Spearman}\left(x_{\cdot,j}, y_{\cdot,s}\right)\right|, \qquad \mathcal{T}_s^{(0)} = \operatorname*{Top3}_j \; w_{j,s}^{(0)}, \tag{4.5}$$

其中 $x_{\cdot,j}$ 为第 $j$ 个化合物的样本向量，$y_{\cdot,s}$ 为第 $s$ 个感官维度的评分向量。该基线完全可复现、解释直接，但恰好暴露出本题的三个困难：共线化合物会轮流占据前列，边际相关分不清直接关联与经由第三变量的间接关联，单条相关系数对缺失与异常值也敏感。

#### 4.3.3 改进方法：共表达图上的拉普拉斯平滑

共表达图提供了“哪些化合物应一起被考虑”的先验。把基线的重要性向量在图上做平滑：

$$\tilde{\boldsymbol{w}}_s = \left(\boldsymbol{I} + \alpha \boldsymbol{L}\right)^{-1} \boldsymbol{w}_s^{(0)}, \tag{4.6}$$

其中 $\alpha > 0$ 控制平滑强度。式(4.6) 的含义是：一个化合物的重要性不仅取决于自身的边际相关，还取决于与它强连接的邻居。孤立的高相关点会被适度压低，成模块出现的高相关化合物则被整体保留。与直接对相关系数设阈值相比，这种做法不切断弱相关边，而是让重要性沿图扩散，因此对阈值的选择不敏感。

$\alpha$ 由验证集上的 Top-3 稳定性选定，不固定为 1：$\alpha \to 0$ 时退化为基线，$\alpha$ 过大则所有化合物的重要性被拉平、Top-3 失去区分度。本文取 $\alpha = 0.3$，这一设定使改进方法始终把基线作为特例。

#### 4.3.4 最终方法：五方法秩融合与稳定性选择

单一方法对共线结构敏感，因此并列保留五种互补方法，在排序层面做融合：

（A） **边际 Spearman**：逐化合物计算与目标维度的 Spearman 相关，在每个目标内做 BH 校正后按 $|r|$ 排序；

（B） **弹性网**：逐目标做弹性网回归，内层 4 折交叉验证在正则化强度与 $l_1$ 比例网格上选参，用系数绝对值作为重要性；

（C） **极端随机树**：逐目标拟合 300 棵树（深度 8、叶节点 3、特征子采样 $\sqrt{P}$），用不纯度下降作为重要性；

**（D） LightGBM 的 SHAP 值**[12]：逐目标做 5 折折外拟合（150 棵树），用折外平均 |SHAP| 衡量每个化合物对单个感官维度的贡献；

**（E） 网络平滑**：把方法 A 的重要性沿共表达图做一步邻居平滑（系数 0.30）。

记方法集合为 $\mathcal{M} = \{A, B, C, D, E\}$，第 $\nu$ 种方法给出的重要性为 $\tilde{w}_{j,s}^{(\nu)}$，在每个目标内排秩得 $R_{j,s}^{(\nu)}$，用 Borda 秩平均融合：

$$\bar{R}_{j,s} = \frac{1}{|\mathcal{M}|} \sum_{\nu \in \mathcal{M}} R_{j,s}^{(\nu)}, \qquad w_{j,s}^{*} = 1 - \frac{\bar{R}_{j,s} - 1}{P - 1}, \tag{4.7}$$

其中 $w_{j,s}^{*} \in [0, 1]$，Top-3 取 $\bar{R}_{j,s}$ 最小的三个化合物。C 与 D 只产生无符号的重要性，融合前用 A 的边际相关符号为其赋号，得到带方向的共识分数。等权秩平均不设可调权重，避免在小样本验证集上调权导致二次过拟合。

这里有两处口径需要如实说明。其一，方法 D 在排序分析中用 5 折折外 SHAP，在 bootstrap 中为控制耗时改用全样本 SHAP，因此秩与入选频率反映的是不同口径下的贡献，二者不可逐项对照，比较应以融合结果为准。其二，方法 E 只改变同一目标内重要性的分布形状，不引入新的数据信息，因此仅作为类别视角的审计，不作为“更优”的证据。

### 4.4 实验设置

数据与划分。样本按 `beer` 分层划分训练、验证与测试集，所有方法在同一划分上比较；缺失值在训练折内插补，测试折只做变换。

主要参数。$K = 10$；图平滑 $\alpha = 0.3$；弹性网用内层交叉验证选正则化强度与 $l_1$ 比例；树模型 300 棵（bootstrap 时为 60 棵）；LightGBM 150 棵（bootstrap 时 60 棵）；bootstrap 重采样 $B = 500$；入选频率只用于报告稳定性，不参与筛选；随机种子 42。

对照与评价分四层：（1）预测层，各方法对感官维度的交叉验证误差；（2）排序层，Top-3 的 bootstrap 入选频率；（3）一致层，方法间 Jaccard 系数；（4）化学层，Top-3 是否落在合理的化合物类别、方向是否与已知代谢路径一致。四层都不出现明显矛盾，才把该组 Top-3 作为最终结果。

### 4.5 结果与分析

500 次 bootstrap 下的纯数据 Top-3 见表 4.2 的中间列。平均入选频率为 0.525，中位数 0.47；150 个条目中 29 个达到 0.8、67 个达到 0.5。方法间的平均 Jaccard 系数

为 0.313，其中边际 Spearman 与网络平滑最高（0.74），边际 Spearman 与弹性网最低（0.20）——后者反映线性正则化与一元相关在共线结构下给出的名单差异最大。

稳定性需要分层看。没有任何一个感官维度的三个条目全部达到 0.8；6 个维度的三个条目都达到 0.5，24 个维度至少两个条目达到 0.5，22 个维度至少一个条目达到 0.8。也就是说，“单个化合物稳定”比“整组 Top-3 稳定”常见得多，因此 Top-3 必须带着入选频率一起报告，只给三个名字会掩盖它对重采样的敏感程度。

图构造方案的扰动同样影响结论：Top-5 与 Top-10 两种 $K$ 近邻图的社区划分 ARI 只有 0.558，硬阈值 $|r| \geq 0.5$ 会产生 48 个孤立点。这说明“Top-3”的稳定性不仅受重采样影响，也受图构造方式影响，本文把 $K = 10$ 作为主方案的依据是它同时满足“无孤立点”与“模块可辨识”，而非它在某个单项指标上最优。

## 4.6 稳定性与化学合理性论证

### 4.6.1 纯数据结果与机制导向结果的分工

统计上排序最靠前的化合物，未必是化学上最该关注的化合物。对双乙酰、DMS 与反式-2-壬烯醛这三个缺陷维度，纯数据 Top-3 都没有选到同名直接化合物：`diacetyl` 的融合名次为 120.8，`DMS` 为 86.5，`t2n` 为 91.4。选中的是蛋白、色度、总硫等风格或物化代理——它们与缺陷维度同受风格与工艺驱动，因而在相关结构上更显著。

这一现象本身是重要发现，而不是方法失败。原因有三：其一，多数样本的缺陷浓度低于阈值，剂量—响应关系被压缩，相关自然变弱；其二，缺陷感知受整体风格与其它缺陷的掩蔽影响，人工评分并不线性反映浓度；其三，`4.csv` 是标准化后的连续值，面板打分的噪声被相对放大。

因此本文把结果分成两栏并列报告（表 4.2）。左栏为纯数据 Top-3，回答“哪些化合物最能预测该感官维度”；右栏为机制导向 Top-3，在融合分数上叠加文献先验后得到，回答“哪些化合物在化学上最应被关注”。前者是主结果，后者是机制审计，两者不是替代关系。把相关当成因果、只报右栏，是这类题目最常见的失分点。

表 4.2　纯数据 Top-3 与机制导向 Top-3 的对照（8 个代表性维度）

| 感官维度 | 纯数据 Top-3 | 机制导向 Top-3 |
|---|---|---|
| diacetyl | pentyl octanoate；ethyl decanoate；$\beta$-phellandrene | diacetyl；pentyl octanoate；ethyl decanoate |
| dms | protein；color；total sulfur | total sulfur；$SO_2$；DMS |
| t2n | glycerol；$\alpha$-phellandrene；$\beta$-phellandrene | E-2-nonenal；dimethoxy-E-citral；Z-dihydro-apofarnesal |
| X4vg | 4-vinylguaiacol；neryl formate；prenyl isobutyrate | 4-vinylguaiacol；4-ethyl-guaiacol；4-ethyl-phenol |
| A_esters_fruity | $\beta$-phellandrene；epicubenol；humulene epoxide II | neryl formate；ethyl decanoate；2-phenylethyl butyrate |
| A_hops_citrus | total hop aroma；cis-dihydro-$\beta$-terpineol；citronellol | citronellol；geraniol；humulene epoxide II |
| A_malt_all | color；caloric value；pH | 2-acetylfuran；5-methylfurfural；furfural |
| bitternes | ethyl octanoate；iso-alpha acids；ethyl decanoate | iso-alpha acids；ethyl octanoate；ethyl decanoate |

机制先验的强度用 $\lambda$ 控制，本文取 $\lambda = 0.5$。这个取值需要明确其性质：它正好是使双乙酰、DMS 与反式-2-壬烯醛三个直接化合物同时进入 Top-3 的最小值，属于“强先验”情景，不是由数据优化得到的最优值。$\lambda$ 的敏感性见表 4.3：$\lambda = 0$ 时机制导向退化为纯数据，重合率为 1.0；$\lambda = 0.5$ 时与纯数据 Top-3 的重合率降到 0.387，平均 bootstrap 稳定性从 0.525 降到 0.303。也就是说，机制导向的代价是可量化的：它用约 40% 的排序稳定性和 60% 的名单重合，换取对三个缺陷维度的化学可解释性。

表 4.3　机制先验强度 $\lambda$ 的敏感性

| $\lambda$ | 与纯数据 Top-3 重合率 | 平均入选频率 | 直接化合物条数 | 与 `6.csv` 的重合率 |
|---|---|---|---|---|
| 0.0 | 1.000 | 0.525 | 5 | 0.460 |
| 0.1 | 0.780 | 0.480 | 5 | 0.393 |
| 0.2 | 0.633 | 0.428 | 5 | 0.387 |
| 0.5 | 0.387 | 0.303 | 9 | 0.313 |

### 4.6.2 化学合理性核对

网络社区与已知化学家族基本对齐（表 4.1）：C2 与 C8 富集酒花萜类，C4 与 C6 富集酵母酯类与醇类，C5 富集麦芽来源的醛、呋喃与吡嗪。Top-3 中有三条链条可以逐环节核对。

**苦味。**`bitternes` 的两栏都给到异 $\alpha$ 酸，与化学事实一致：异 $\alpha$ 酸是酒花 $\alpha$ 酸经异构化生成的苦味物质，直接决定苦度。需要指出，这一条中“两栏一致”部分属于定义性一致——`6.csv` 中的 Iso-alpha acids 与 `1.csv` 的 `bitterness` 列同源，因此它不构成独立证据。

**挥发性酚。**`X4vg` 的两栏都落在 4-乙烯基愈创木酚及其衍生物上，对应阿魏酸经酵母 Pad1 脱羧酶生成 4VG 的路径，其阈值约 0.2 mg/L，在非小麦风格中即为酚缺陷。这一条同时满足类别匹配、来源匹配与剂量可算，是本文最可靠的一组 Top-3。

**酒花柑橘香。**`A_hops_citrus` 的两栏都落在香叶醇、里那醇与香茅醇上。三者均为单萜醇，且香叶醇在发酵中可转化为香茅醇，二者的协同是柑橘香的主要来源，因此按“家族”而非单化合物解读更合适。

反过来，酯香维度 `A_esters_fruity` 的纯数据 Top-1 是 $\beta$-菲兰烯（入选频率 0.782），一种酒花萜烯，而不是任何酯类。这说明“果香由酯类决定”这一教科书结论在本数据中并不成立：酯类与萜烯受同一酒花添加与发酵条件驱动，边际相关上萜烯反而更强。这条反例提示，Top-3 的名字必须与化学类别、剂量、阈值一起读，不能只看排名。

类别富集检验的结果也支持“只作辅助证据”的定位：Top-3 层面有 3 个类别显著富集（理化指标，富集倍数约 17.8，$q = 0.0023$），Top-10 层面有 9 个显著（富集倍数 8.9，$q = 0.00085$；有机酸约 23.1，$q = 0.027$）。显著项集中在理化指标与有机酸，恰好是题面所说的“由多化合物加和得到的派生属性”，说明这类列在共表达图中天然处于枢纽位置，容易被选中，解释时应与具体组分对照阅读。

最后一点可作为与问题一的交叉检查：某化合物若在此被判为某维度的关键因素，却在问题一的多任务模型中没有稳定系数，则两者至少有一个需要复查。本文把这种不一致作为诊断信息保留——缺陷维度在问题一中 $R^2$ 接近 0 或为负，正与本节的“直接化合物的边际信号弱于代理”互为印证。

## 4.7 讨论

问题二的结论受三方面限制。

第一，相关不等于因果。共表达图上的边可能来自共同上游调控、批次差异或样

品制备，本文用多方法融合与 6.csv 交叉校验降低了这种风险，但不能证明因果。若要用干预实验或代谢网络先验替代纯相关图，需要额外的实验数据，本文不具备。

第二，化合物注释与类别划分依赖 8.xlsx 与文献，若注释有误，化学合理性判断会跟着错。本文把类别核对过程写进正文与附录，便于复查；但这只能降低而不能消除注释带来的不确定性。

第三，Top-3 是“给定数据与给定感官维度下的紧凑摘要”，不是“只有这三个化合物重要”。排名第四、第五的化合物在特定风格或特定缺陷场景中可能更关键，实际使用时不应把 Top-3 当作硬阈值。同样，$\lambda = 0.5$ 的机制导向结果只适用于机制审计，不能作为“最强预测因子”的结论引用。

# 5 问题三：“风味指纹”与风格条件生成

## 5.1 问题分析

问题三包含三个相互关联的子任务：以 tasting_category_fine 为条件学习风格生成模型，使给定风格（如 Tripel、Kriek、Lambic）能生成合理的化合物谱；由生成的化合物谱给出对应的感官画像，即“风味指纹”；完成跨风格迁移，例如把 Pils/Lager 的化合物谱迁移为 Tripel 风格，同时保证 DMS、双乙酰、4VG、反式-2-壬烯醛与 stale hops 等缺陷化合物不恶化。

与问题一、二相比，这里没有唯一正确的答案。同一风格的不同酒在化合物谱上差异很大，生成模型不能只记住训练样本；而风格标签在 7.csv 中分布不均，Tripel 有 28 个样本，Kriek 10 个、Lambic 11 个，最少的 Faro 只有 3 个，逐风格单独建模必然过拟合。这两点决定了模型必须做到“参数少、协方差可收缩”。

本文没有采用条件变分自编码器或条件 GAN。这类模型在样本充足时拟合能力强，但在 $N = 250$、$G = 22$ 的规模下，其参数量与训练方差都远超数据所能支撑的范围，且生成结果难以做逐化合物的阈值约束。本文改用“条件高斯 copula 学风格分布、高斯最优传输做跨风格迁移、风格感知上限约束缺陷”的路线：三者的参数都可从 250 个样本稳定估计，每一步都能写出闭式形式，缺陷约束也能直接作用在指定列上。

评价上本文不追求单一指标最优。生成质量本就无真值，风格分类器可以因模式崩塌而虚高，多样性可以因生成不合理化合物而虚高，缺陷比例可以靠把风味一起压没来降低。因此评价拆成分布保真、风格保真、多样性、缺陷控制与感官一致五个维度，同时报告。

## 5.2 风味指纹与评价指标

以 7.csv 的 tasting_category_fine 为风格标签 $z_i$，通过 beer 列与 1.csv 连接，得到化合物谱与风格的配对数据；属于风格 $g$ 的样本集合记为 $\mathcal{D}_g$。本文把风格 $g$ 的风味指纹定义为其化合物谱均值与感官画像均值的组合：

$$\mathcal{F}_g = (\bar{\boldsymbol{x}}_g,\ \bar{\boldsymbol{y}}_g)\,, \qquad \bar{\boldsymbol{x}}_g = \frac{1}{|\mathcal{D}_g|}\sum_{i\in\mathcal{D}_g}\boldsymbol{x}_i, \quad \bar{\boldsymbol{y}}_g = \frac{1}{|\mathcal{D}_g|}\sum_{i\in\mathcal{D}_g}\boldsymbol{y}_i. \tag{5.1}$$

该定义不替代完整的生成分布，而是给生成结果提供一个可比较的“风格中心”：生成样本既要接近 $\bar{\boldsymbol{x}}_g$，又要保留风格内部的合理变异，不能退化为均值复制。

五个评价维度如下。

分布保真用 RBF 核的最大均值差异衡量：

$$\mathrm{MMD}^2 = \frac{1}{n^2}\sum_{i,i'}k(\boldsymbol{x}_i,\boldsymbol{x}_{i'}) + \frac{1}{m^2}\sum_{j,j'}k(\tilde{\boldsymbol{x}}_j,\tilde{\boldsymbol{x}}_{j'}) - \frac{2}{nm}\sum_{i,j}k(\boldsymbol{x}_i,\tilde{\boldsymbol{x}}_j), \tag{5.2}$$

其中 $\tilde{\boldsymbol{x}}$ 为生成样本，$k(\cdot,\cdot)$ 为 RBF 核，核宽按中位启发式取。

风格保真用真实数据训练的风格分类器在生成样本上的 top-1 命中率，辅以生成样本到目标风格中心的马氏距离。多样性用覆盖度与精确度：以真实样本留一最近邻距离的中位数为阈值，覆盖度是“至少被一个生成样本落入该阈值”的真实样本比例；以该距离的 95% 分位为阈值，精确度是“到真实集最近邻距离不超过该阈值”的生成样本比例。缺陷控制用各缺陷列超过给定阈值的比例。感官一致用问题一的模型为生成的化合物谱预测感官画像，再与 $\bar{\boldsymbol{y}}_g$ 比较 RMSE 与 Pearson 相关。

五项必须同时报告。只提高风格命中率可能意味着模式崩塌——生成样本都挤在风格中心附近；只提高多样性可能生成不合理的化合物；只压低缺陷比例可能把该风格应有的风味一起压掉。本文用这五项构成一张对照表，避免用单一指标下结论。

## 5.3 模型构建：从风格均值到缺陷约束

### 5.3.1 基线方法：风格均值与全局协方差采样

最简单的风格条件生成器是“风格均值加高斯噪声”：对每个风格 $g$ 估计均值 $\boldsymbol{\mu}_g$，用所有风格合并后的协方差 $\boldsymbol{\Sigma}_{\mathrm{pool}}$ 注入随机性：

$$\tilde{\boldsymbol{x}}^{(g)} = \boldsymbol{\mu}_g + \boldsymbol{\Sigma}_{\mathrm{pool}}^{1/2}\boldsymbol{z}, \qquad \boldsymbol{z}\sim\mathcal{N}(\boldsymbol{0},\boldsymbol{I}). \tag{5.3}$$

它的变体是“全局协方差加风格均值平移”，即保留全局相关结构，只把均值移到目标风格。两者训练快、可复现，能给出风格中心与基本变异，但无法刻画风格内部协方差的差异，在零膨胀的长尾化合物上也容易生成不合理的极端值。

### 5.3.2 改进方法：条件高斯 copula

化合物浓度具有强零膨胀与长尾，直接对浓度建高斯模型会生成负值。本文先用经验分布把每个化合物映射到标准正态分数：

$$z_{i,j} = \Phi^{-1}\left(F_j(x_{i,j})\right), \tag{5.4}$$

其中 $F_j$ 为第 $j$ 个化合物在训练集上的经验分布函数，$\Phi$ 为标准正态分布函数。变换后各列边际为正态，风格间的差异只剩均值与相关结构。

对风格 $g$ 估计均值 $\boldsymbol{\mu}_g$ 与协方差 $\boldsymbol{\Sigma}_g$。当 $|\mathcal{D}_g|$ 较小时，样本协方差不可靠，用收缩估计：

$$\boldsymbol{\Sigma}_g^{(\lambda)} = (1-\lambda)\hat{\boldsymbol{\Sigma}}_g + \lambda\boldsymbol{\Sigma}_{\text{pool}}, \qquad \lambda = \frac{n_0}{n_0 + |\mathcal{D}_g|}, \tag{5.5}$$

其中 $n_0 = 20$ 控制收缩强度，$\boldsymbol{\Sigma}_{\text{pool}}$ 为合并协方差（用 Ledoit–Wolf 估计）。样本越少，$\lambda$ 越接近 1，协方差越向全局结构靠拢。

生成时从风格条件分布抽样，再逆变换回浓度空间：

$$\boldsymbol{z} \sim \mathcal{N}\left(\boldsymbol{\mu}_g, \boldsymbol{\Sigma}_g^{(\lambda)}\right), \qquad \tilde{x}_j = F_j^{-1}\left(\Phi(z_j)\right), \tag{5.6}$$

并对 $\tilde{x}_j$ 做非负截断。式(5.6) 即条件高斯 copula：它保留每个化合物的边际分布与风格内的相关结构，同时把风格信息压缩为均值与协方差两个量。与风格均值基线相比，收缩协方差在小样本风格上更稳定；与 CVAE 相比，它没有神经网络的训练方差，在本题的数据规模下更可靠。

### 5.3.3 最终方法：风格感知的缺陷约束

生成模型只保证“像这个风格”，不保证“缺陷不超标”。记缺陷化合物集合为 $\mathcal{J}$，其严格阈值为 $\tau_j$，风格 $g$ 中化合物 $j$ 的 75% 分位数为 $q_{g,j}$，定义风格感知上限

$$\bar{c}_{g,j} = \max\left(\tau_j,\ q_{g,j}\right), \qquad \tilde{x}_j \leftarrow \min\left(\tilde{x}_j,\ \bar{c}_{g,j}\right) \quad (j \in \mathcal{J}). \tag{5.7}$$

这里取“阈值”与“风格分位数”的较大者，是为了同时避免两种错误：若只用 $\tau_j$，Tripel 这类风格本身的 DMS 与双乙酰水平就高于通用阈值，一压会把风格特征抹平；若只用 $q_{g,j}$，则会放任某些样本显著超出安全水平。取上限后，生成结果既不破坏风格基线，也不产生风格正常波动之外的极端值。

有两处需要单独说明。其一，4VG 的风格上限不用式(5.7)，而取固定值 0.10 mg/L：小麦风格的 4VG 分位数显著高于非小麦风格的安全值，若按风格分位数设上限，等于承认小麦风格的酚味可以无限接近其自身分位水平。其二，stale hops 不是单一化合物，本文用反式-2-壬烯醛、DMS、ethyl 2-methylbutyrate、ethyl isovalerate 与 4VG 五列的标准化均值构造代理，并在迁移中对每一列单独施加“不高于源样本”的约束。各缺陷的阈值与依据见表 5.1。

表 5.1　缺陷化合物的严格阈值与取值依据

| 缺陷 | 对应列 | 严格阈值 | 单位 | 依据 |
|---|---|---|---|---|
| DMS | `DMS` | 17.25 | $\mu$g/L | 附件阈值与文献综合 |
| Diacetyl | `X2.3.butanedione` | 0.09 | mg/L | 附件阈值与文献综合 |
| 4VG | `X4VG` | 0.10 | mg/L | 非小麦风格安全值 |
| trans-2-nonenal | `X.E..2.nonenal` | 0.10 | $\mu$g/L | 文献常用阈值 |
| stale hops | 五列复合代理 | — | — | 非单一化合物，见正文 |

反式-2-壬烯醛的单位问题在第 2 章已说明：附件标注为 mg/L，但数值范围与文献常用的 $\mu$g/L 阈值同一量级，本文按 $\mu$g/L 解释；若按标注单位，全部样本都远低于检出限，该维度将失去区分度。

## 5.4　跨风格迁移：最优传输与边际校准

设源风格为 $g$、目标风格为 $g'$。在正态分数空间中，均值与协方差匹配意义下的高斯最优传输映射[13]为闭式：

$$T_{g\to g'}(\boldsymbol{z}) = \boldsymbol{\mu}_{g'} + \boldsymbol{\Sigma}_{g'}^{1/2}\boldsymbol{\Sigma}_{g}^{-1/2}\left(\boldsymbol{z} - \boldsymbol{\mu}_{g}\right), \tag{5.8}$$

其中矩阵平方根用对称半正定分解计算。式(5.8) 把源样本映射到目标风格，再逆变换回浓度空间。与“只加风格均值差”相比，它多了协方差校正，能同时改变化合物的相关结构。

仿射映射只匹配均值与协方差，不保证各化合物的边际形状，对零膨胀的痕量化合物尤其明显。因此迁移后对每一列再做一次秩映射，把生成样本的分位数对齐到目标风格的经验分布：

$$\tilde{x}_{i,j} \leftarrow Q_{g',j}\left(\frac{\mathrm{rank}(\tilde{x}_{i,j}) - 1/2}{n}\right), \tag{5.9}$$

其中 $Q_{g',j}$ 为目标风格化合物 $j$ 的经验分位数函数。该步之后每一列的边际与目标风格严格一致，因此后文的 MMD 与覆盖度衡量的是化合物之间的相关结构，而非整体分布形状——引用这两个数值时必须带上这一口径。

按缺陷处理方式，迁移分三个变体：raw 只做式(5.8) 与式(5.9)，不加任何缺陷约束；strict 把缺陷列投影到严格阈值 $\tau_j$；style 投影到式(5.7) 的风格上限。三者共用同一映射，差别只在投影，因此可以直接比较“安全”与“风格真实”两种取向的代价。

## 5.5 实验设置

生成模型的输入取 `8.xlsx` 校准后的 70 个化合物线性浓度，做 log1p 与逐列标准化。协方差用 Ledoit–Wolf 估计，收缩强度 $n_0 = 20$；每个风格每种模型生成 300 条样本；感官代理用 PLS，做嵌套 5 折交叉验证，平均 $R^2 = 0.220$。

风格分层划分训练与测试集，保证每个风格在测试集中至少有一个样本；小样本风格采用式(5.5) 的收缩估计，并在结果中单独标注其不确定性。对照模型为：风格均值加噪声（mean-noise）、全局协方差加风格均值平移（global-cov）、条件高斯 copula、copula 加缺陷约束（style cap），以及 OT 迁移。所有模型共用同一划分与随机种子 42。

## 5.6 结果与分析

三风格平均的五维评价见表 5.2。OT 加约束在分布保真（MMD 0.038）、覆盖度（0.863）与风格命中率（0.981）三项上都最好；条件 copula 的风格命中率接近（0.974），但 MMD 为 0.111、感官 RMSE 为 0.132，说明它更贴近风格中心却牺牲了分布与感官一致性；均值加噪声的命中率只有 0.851、覆盖度 0.300，是典型的模式崩塌——生成样本挤在风格均值附近，多样性几乎消失。

表 5.2　生成模型的五维评价（Tripel、Kriek、Lambic 三风格平均）

| 指标 | 均值加噪声 | 全局协方差 | 条件 copula | OT 加约束 |
|---|---|---|---|---|
| 分布保真：$\mathrm{MMD}^2$ | 0.063 | 0.066 | 0.111 | **0.038** |
| 风格保真：随机森林命中率 | 0.851 | 0.667 | 0.974 | **0.981** |
| 多样性：覆盖度 | 0.300 | 0.233 | 0.430 | **0.863** |
| 缺陷控制：超严格阈值率 | 0.61/0.67/0.40 | 0.57/0.60/0.43 | 0.56/0.73/0.07 | 0.59/0.81/0.00 |
| 感官一致：画像 RMSE | 0.090 | 0.095 | 0.132 | **0.090** |

缺陷一栏需要分开读。OT 加约束把反式-2-壬烯醛的超严格阈值率压到 0，但 DMS 与双乙酰仍有 0.59 与 0.81，原因不是约束失效，而是 Tripel、Kriek、Lambic 三个风格的 75% 分位数本身就高于附件给出的严格阈值（Tripel 的 DMS $q_{75} = 55.0$ $\mu$g/L、双乙酰 $q_{75} = 0.589$ mg/L，均高于 17.25 与 0.09 的阈值）。相对风格上限 $\bar{c}_{g,j}$ 的超阈值率在四类缺陷上均为 0.000。因此“风格允许”与“绝对安全”是两套口径，本文同时报告：前者说明生成结果没有超出该风格自身的正常波动，后者说明它在绝对意义上是否超标。把前者误写成后者，是这类生成任务最容易出现的夸大。

4VG 在所有风格与所有方案下都远低于其上限，在本数据中缺乏区分度，这一点在解释结果时需要注明，否则读者会以为该列没有参与约束。

迁移结果方面，源风格 Pils/Lager 的 Tripel 命中率为 0.00，经 OT 迁移后三个变体（raw、strict、style）的 Tripel 命中率均为 0.91，与 Tripel 画像的 Pearson 相关分别为 0.974、0.856 与 0.972，说明风格方向迁移成功。

三个变体的差别体现在缺陷列上。raw 把 DMS、双乙酰、反式-2-壬烯醛从源样本的 15.8 $\mu$g/L、0.117 mg/L、0.004 $\mu$g/L 抬到 41.8、0.418、0.115，11 个源样本全部恶化；strict 把它们压到 13.7、0.047、0.004，超严格阈值率为 0，且相对源样本的恶化比例为 0；style 保留 Tripel 的风格基线（39.8、0.398、0.099），相对风格上限的超标率为 0，但相对 Pils/Lager 的升高是风格本身应有的变化，不应读作缺陷恶化。前者对应“安全优先”，后者对应“风格优先”，两种取向的选择取决于用途：配方筛选可用 style，成品放行必须用 strict。

关键化合物的迁移幅度符合化学预期。乙醇由 5.19% 升至 8.79%，甘油由 1.64 升至 3.11 g/L，乙酸乙酯由 10.8 升至 40.3 mg/L，乙酸异戊酯由 1.15 升至 4.62 mg/L，异戊醇由 27.9 升至 54.6 mg/L——酯类与高级醇温和上升，与 Tripel 高酯、高酒精度、较厚酒体的风格特征一致。酒花萜类升幅最大，里那醇由 0.062 升至 1.14 mg/L，约为 Tripel 中位数 0.372 mg/L 的 3 倍，却只达其均值 2.97 mg/L 的 38%。同一结果在中

位数口径与均值口径下评价相反，说明点估计在长尾化合物上难以同时满足两种口径，后续应以分位数约束取代均值匹配，而不是继续调 OT 的均值映射。

风格画像的案例结果为：Tripel、Kriek、Lambic 的生成画像与真实风格中位数的 Pearson 相关分别为 0.968、0.957、0.990，RMSE 为 0.051、0.147、0.071。Kriek 的误差最大，反映其真实感官分布本身更分散，单一的风格中心不足以概括。

### 5.7 讨论

生成模型的评价没有统一真值，本文用五维指标加案例，但仍有三点限制。

第一，风格分类器本身是在真实数据上训练的。若真实标签存在噪声，生成样本的“保真”分数会继承这种噪声，因此本文同时报告马氏距离与感官一致性，避免只依赖分类器。

第二，缺陷阈值来自 `8.xlsx` 与文献，不同风格、不同市场的阈值并不相同。本文把阈值作为可配置参数，并在敏感性分析中变动阈值，检查结论是否稳健；但“某个浓度是否算缺陷”这一问题最终仍需工艺与标准来判断，不是数据能单独回答的。

第三，式(5.8) 假设正态分数空间中的风格差异可由均值与协方差线性刻画。若风格流形高度非线性，线性映射只能迁移部分特征。改用核最优传输或条件流模型可以缓解，但必须同时保留缺陷约束与逐化合物的可解释性检查，否则会把“像”与“安全”两个目标混在一起。

此外还有两处口径需要在结论前交代。其一，stale hops 的代理列里包含 ethyl 2-methylbutyrate 与 ethyl isovalerate 两个果香酯类，把它们纳入“不恶化”约束会同时抑制 Tripel 应有的酯类上升，因此 strict 迁移对这两列是保守偏置，不能读作对 stale hops 的独立实测。其二，部分风格样本过少（`Faro` 仅 3 个），生成模型在这些风格上的多样性指标既可能被高估也可能被低估，本文不把少数风格的结果外推到所有商业啤酒，而把它们作为“在本数据条件下可行”的方案，并建议补充同风格样本后复评。

## 6 结论与建议

### 6.1 主要结论

本文完成了数据对齐、分级评分、关键化合物识别与风格条件生成四段工作，三问共用一套数据底座与符号体系，结论如下。

### 6.1.1 问题一

在缺少原始 0–6 评分的条件下，“连续潜变量回归加有序校准”两层建模是可行的：折外等权融合在 5 折 × 3 次重复下取得宏平均 $R^2 = 0.227$、Spearman 0.432，保序校准后 QWK 为 0.376。逐维结果呈现清晰的化学梯度——酸度（0.690）、酒精度（0.678）、苦味（0.604）最强，barnyard（−0.039）等阈值型缺陷维度接近 0 甚至为负，说明“有明确化学载体且近似单调”的维度可预测，而“超过阈值才被感知且风格内变异小”的维度不可预测。

改进的边际收益需要如实看待。等权融合相对最强单体（极端随机树 0.223）只高 0.004，二者折间误差棒重叠；融合的实际价值在于折间方差更小与逐目标更均衡，而非宏平均上的显著提升。风格先验在岭回归上带来 +0.024，在融合模型上只带来 +0.012，因为树模型已能从化合物谱间接识别风格。

缺失稳健性在本文的遮蔽机制下可以接受：随机遮蔽 30% 化合物时 $R^2$ 相对下降 19.3%、RMSE 相对上升 3.8%，非随机缺失（平均 24.8%）下降 10.9%，与 20% 随机缺失的 11.5% 接近。保序校准把 0 级预测比例由 min-max 的 7.6% 提到 11.3%，缓解了“向中间档压缩”，但仍远低于参考分级的 23.3%，尾部依旧被低估。

### 6.1.2 问题二

共表达图的结构与已知化学家族基本对齐：$K = 10$ 的近邻图给出 231 个节点、1 683 条边、8 个社区，模块度 0.586，酒花萜类（C2、C8）、酵母酯类与醇类（C4、C6）、麦芽来源的醛与呋喃（C5）各自成模块。但社区并不严格等于化学家族，同一模块内常混有酯、萜与醇，因为它们受同一发酵条件驱动，所以社区只能作为“哪些化合物应一起考虑”的先验。

稳定性必须按条目而非按整组报告。500 次 bootstrap 下平均入选频率 0.525、方法间 Jaccard 平均 0.313；没有任何一个感官维度的三个条目全部达到 0.8，而 24 个维度至少两个条目达到 0.5。一个只给三个名字、不带频率的 Top-3 会掩盖它对重采样的敏感程度。

最重要的发现是统计显著与化学相关在本数据上出现了分离。双乙酰、DMS 与反式-2-壬烯醛的纯数据融合名次分别为 120.8、86.5、91.4，选中的是蛋白、色度、总硫等风格或物化代理；只有在叠加文献先验（$\lambda = 0.5$）后，三个直接化合物才回到 Top-3，而代价是名单与纯数据重合率降到 0.387、平均稳定性降到 0.303。这说明在本数据中，缺陷直接化合物的边际信号弱于其风格混杂，相关排序不能直接当作因果结论。

### 6.1.3 问题三

条件高斯 copula 加高斯最优传输的路线在本题的数据规模下是有效的。三风格平均 MMD 为 0.038、覆盖度 0.863、风格命中率 0.981，均优于均值加噪声（0.063/0.300/0.851）、全局协方差（0.066/0.233/0.667）与纯 copula（0.111/0.430/0.974）。后者的命中率高但 MMD 与感官 RMSE 更差，说明它更贴近风格中心却牺牲了分布形状——这正是“单一指标会误导”的例证。

跨风格迁移成功且可定向。Pils/Lager 的 Tripel 命中率为 0.00，迁移后三个变体均为 0.91，与 Tripel 画像的 Pearson 相关为 0.974（raw）、0.856（strict）、0.972（style）。关键化合物的迁移幅度与化学预期一致：乙醇 5.19% 升至 8.79%，乙酸乙酯 10.8 升至 40.3 mg/L，里那醇 0.062 升至 1.14 mg/L。

缺陷控制必须区分两套口径。相对严格阈值，DMS 与双乙酰的超阈值率仍为 0.59 与 0.81，因为 Tripel、Kriek、Lambic 三个风格的 75% 分位数本身就高于附件给出的通用阈值；相对“风格上限 $\max(\tau_j, q_{g,j})$”，四类缺陷的超阈值率均为 0。前一口径偏保守，后一口径更符合风格真实性，二者不可互相替代：成品放行应按严格阈值，配方筛选可用风格上限。

## 6.2 对酿造实践的建议

**第一，把化合物—感官模型作为配方与工艺调整的辅助工具，而不是人工品评的替代品。**模型能快速筛出可能影响目标风味的化合物并给出相对等级，但绝对档位依赖校准假设，最终判断仍需品评小组与生产条件。

**第二，对关键化合物建立分风格的监控窗口。**问题二给出的 Top-3 可作为优先监测项，但应与问题一的维度权重、问题三的缺陷上限结合使用，避免只盯少数化合物而忽略整体风味平衡。

**第三，缺陷控制应前置到原料与发酵过程。**DMS 来自麦芽的 SMM 与 DMSO 热分解，双乙酰来自 $\alpha$-乙酰乳酸的氧化脱羧，4VG 来自阿魏酸脱羧，反式-2-壬烯醛来自亚油酸氧化——这些环节都在灌装之前。生成模型的阈值约束只能用于配方筛选，不能替代工艺控制。

**第四，数据积累应优先补齐“原始 0–6 评分”与“缺失原因”。**本文的校准层是对缺失标签的补救，不是替代；若能拿到原始评分卡与检测限信息，问题一的绝对等级精度与问题三的感官评价都会明显改善。

### 6.3 局限与展望

本文的局限有四方面。**其一**，问题一缺少真实 0–6 标签，分级结果的绝对水平依赖校准锚点，QWK 衡量的是同一连续信号在两种离散化下的一致性，不等于与人工评分逐档吻合。**其二**，问题二的关联基于观测数据，相关不等于因果，共表达图上的模块可能混合了共同调控、批次效应与测量误差。**其三**，问题三的生成质量缺少统一真值，五维指标与案例只能提供相对比较，不能证明生成样本在真实酿造中可行；感官代理模型的嵌套交叉验证平均 $R^2$ 只有 0.220，缺陷维度的预测尤其弱。**其四**，外部数据只能整合到 22 个风格层级，与附件没有共同酒名、酒厂或条码，无法逐酒连接，只能用于风格级原型与效度校验。

后续工作可从三个方向展开。一是引入原始感官评分与检测限数据，把分级校准从“分位数锚定”升级为“有序标签监督”。二是用干预实验或代谢网络先验替代纯相关图，提升问题二因果解释的可信度。三是把问题三的生成模型与工艺参数连接，形成“工艺—化合物—感官”的闭环优化，而不是只在化合物层面做条件生成。

## 参考文献


[1] 刘倩，贾建华，白艳龙，等，啤酒风味物质及分析技术研究进展，中国酿造，42(8)：20-27，2023。

[2] 李俊杰，刘智颖，赵丽娜，等，基于固相微萃取结合气相色谱-质谱联用技术分析苦荞啤酒中关键香气物质，中国酿造，44(7)：139-147，2025。

[3] Vanderhaegen B, Neven H, Verachtert H, et al., The chemistry of beer aging: a critical review, Food Chemistry, 95(3): 357-381, 2006.

[4] Schreurs M, Piampongsant S, Roncoroni M, et al., Predicting and improving complex beer flavor through machine learning, Nature Communications, 15: 2368, 2024.

[5] Little R J A, Rubin D B, Statistical Analysis with Missing Data, 3rd ed. Hoboken: Wiley, 2019.

[6] Polozoff S, Top Beer Information, `https://www.kaggle.com/datasets/stephenpolozoff/top-beer-information`, 2026-10-24.

[7] Cohen J, Weighted kappa: nominal scale agreement with provision for scaled disagreement or partial credit, Psychological Bulletin, 70(4): 213-220, 1968.

[8] Hastie T, Tibshirani R, Friedman J, The Elements of Statistical Learning, 2nd ed. New York: Springer, 2009.

[9] Wold S, Sjöström M, Eriksson L, PLS-regression: a basic tool of chemometrics, Chemometrics and Intelligent Laboratory Systems, 58(2): 109-130, 2001.

[10] Efron B, Bootstrap methods: another look at the jackknife, The Annals of Statistics, 7(1): 1-26, 1979.

[11] Langfelder P, Horvath S, WGCNA: an R package for weighted correlation network analysis, BMC Bioinformatics, 9: 559, 2008.

[12] Lundberg S M, Lee S I, A unified approach to interpreting model predictions, Advances in Neural Information Processing Systems, 30: 4765-4774, 2017.

[13] Peyré G, Cuturi M, Computational optimal transport, Foundations and Trends in Machine Learning, 11(5-6): 355-607, 2019.